

Opis wariantu przetwarzania danych

Wynikiem obliczeń mnożenia macierzy jest macierz C będąca iloczynem macierzy A i B. Każdy element macierzy wynikowej w **wierszu** i **kolumnie** jest sumą iloczynów odpowiadających sobie słów pochodzących z **wiersza** macierzy A i **kolumny** macierzy B. Przetwarzanie na GPU odbywa się poprzez realizację zadań przez bloki wątków. Każdy wątek oblicza co najmniej jedną wartość tablicy C, a wątki kwadratowego bloku wątków o wielkości $BS \times BS$ obliczają blok tablicy wynikowej C (zakres wierszy i zakres kolumn). Dla wzrostu lokalności dostępu do danych wykorzystywana jest pamięć współdzielona bloku wątków. Obliczenia realizowane są w krokach polegających na używaniu danych dostarczonych do pamięci współdzielonej wspólnie przez wątki bloku przed każdym krokiem obliczeń. Dane te nie zawierają pełnych wierszy/kolumn macierzy A/ B, lecz fragmenty tych wierszy pozwalające na pracę na ograniczonej wielkości pamięci współdzielonej. Dla efektywnego zrównoleglenia operacji przesłania danych pomiędzy pamięcią globalną a pamięcią współdzieloną każdy wątek bierze udział w tym przesłaniu przenosząc po jednym słowie tablicy A i tablicy B. Liczba przeniesionych w ten sposób słów równa $BS \times BS$ z każdej macierzy A i B pozwala na udostępnienie wątkom w pamięci współdzielonej $BS \times BS$ unikalnych par wiersz-kolumna pozwalających na obliczenia $BS \times BS$ wyników częściowych (każdy wynik jest liczony przez jeden wątek). Wynik częściowy obliczony przez wątek jest w kolejnym kroku uzupełniany przez ten sam wątek w oparciu o kolejne porcje danych (fragmenty tablic A i B) przeniesione z pamięci globalnej do pamięci współdzielonej. Tak działa oryginalna wersja kodu udostępniona z pakietu przykładów dystrybucji CUDA-NVIDIA.

Zadanie projektowe

Zadaniem Studentów jest zbadanie czy zwiększenie ilości pracy realizowanej przez wątek (obliczanie większej liczby wyników w każdym kroku) pozwoli na wzrost efektywności obliczeń. Wzrost liczby wyników częściowych obliczanych, w każdym z opisanych powyżej etapów, może spowodować wzrost efektywności przetwarzania. Wzrost ten może wynikać z dodatkowego wielokrotnego wykorzystania tych samych wierszy i kolumn macierzy w stopniu zależnym od liczby wyników liczonych przez wątek. Przykładowo wątek obliczając dwa wyniki cząstkowe potrzebuje tylko 50% danych więcej gdyż może mnożyć ten sam fragment wiersza macierzy A przez dwa różne fragmenty kolumn macierzy B.

Należy opracować (opis i rysunki) i zaimplementować w kodzie (wyjaśnienia dotyczące postaci kodu) sposób pobierania danych do pamięci współdzielonej zapewniający:

- łącznie dostępow w minimalną liczbę transakcji z pamięcią,
- maksymalną krotność użycia raz pobranych danych.

Należy określić wielkość przesyłanych danych do pamięci globalnej (zależną od ilości wyników obliczanych przez wątek).

Informacje pomocnicze

Dla karty NVIDIA GeForce GTX 1080 ilość pamięci współdzielonej dostępnej dla bloku wątków wynosi:

Total amount of shared memory per block: 49152 bytes

a cała pamięć współdzielona multiprocessora to

Total shared memory per multiprocessor: 98304 bytes

Słowa tablicy mają rozmiar 4 bajtów. Dla bloku $32 \times 32 = 1024$ (dla wariantu jednego wyniku obliczanego przez wątek) w pamięci współdzielonej musi się znaleźć jednocześnie $4096 \times 2 = 8192$ bajtów pochodzących z obu tablic. Wzrost liczby wyników obliczanych przez wątek powoduje wzrost krotności odczytów tych samych danych z pamięć współdzielonej.

Należy określić teoretycznie jaką liczbę wyników może obliczyć wątek w konfiguracji bloków 32×32 i 16×16 .

Należy sprawdzić eksperymentalnie, dla danych zapewniających obciążenie karty przez cały czas obliczeń, jak liczba wyników obliczanych przez wątek wpływa na prędkość przetwarzania danych.

Informacja dla karty GeForce GTX 1080

Karta posiada 20 multiprocesorów mogących przetwarzać maksymalnie dwa bloki po 32x32 wątki każdy. Wynika stąd, że przetwarzać można na tej karcie równocześnie 40 bloków po 1024 wątki obliczających równocześnie **co najmniej** (przy jednym wyniku na wątek) $40 \cdot 1024 = 256 \times 160$ wyników. Zwielokrotnienie wielkości tablicy wynikowej pozwoli na nasycenie obliczeniami karty przy zwiększeniu liczby wyników obliczanych przez jeden wątek.

Jeden wynik obliczany przez wątek bloku o wielkości $BS \cdot BS$ to BS -krotne wykorzystanie danych z pamięci współdzielonej. Obliczanie dwóch wyników to konieczność pobrania w każdym etapie $3 \cdot BS \cdot BS$ słów które będą w 33,33 % wykorzystane $2 \cdot BS$ krotnie i w 66,66 % wykorzystane BS krotnie (średnio $4/3 \cdot BS$ razy). Obliczanie czterech wyników to konieczność pobrania w każdym etapie $4 \cdot BS \cdot BS$ słów i możliwość $2 \cdot BS$ - krotnego użycia raz pobranych danych.

Ze względu na wielkość pamięci współdzielonej dostępnej dla bloku wątków blok danych o wielkości $BS \cdot BS$ mieści się w niej co najwyżej $49152/4/BS/BS$ razy (gdzie 4 jest rozmiarem słowa danych). Zatem: dla bloku wątków o wielkości 32x32 można załadować nie więcej niż 12 bloków danych o wielkości 32x32, a dla bloku wątków o wielkości 16x16 można załadować nie więcej niż 48 bloków danych o wielkości 16x16. 12 bloków danych to po 6 bloków z każdej tablicy i teoretycznie 36 wyników obliczanych przez wątek z bloku 1024 wątków. 48 bloków to $24 \cdot 24$ wyników obliczanych przez wątek z bloku 256 wątków, ale również odpowiednio potrzeba przechowywania przez każdy wątek odpowiednio 36 lub $24 \cdot 24$ wyników tymczasowych w rejestrach (lub pamięci „lokalnej”). Takie ekstremalne wykorzystanie pamięci współdzielonej powoduje drastyczny spadek maksymalnej zajętości multiprocesora.

Warto zwrócić uwagę na następujące fakty:

- większa ilość pracy dla każdego wątku wymaga większych rozmiarów obliczanej instancji danych, które podczas wielokrotnego pobierania z pamięci globalnej gorzej wpasują się w ograniczony rozmiar pamięci podręcznej L2 karty. Warto zatem dla zapewnienia jednakowych warunków pomiarowych dla **uruchomień z różną liczbą wyników** obliczanych przez wątek zadbać o jednakową wielkość danych dla wszystkich uruchomień – wielkość zapewniającą pracę dla wszystkich wątków jednocześnie obsługiwanych w systemie.
- wzrost wielkości pamięci współdzielonej używanej przez blok wątków powoduje brak możliwości jednoczesnego uruchamiania maksymalnej liczby bloków gdyż następuje wyczerpanie, przez duże żądania zasobowe kilku bloków, zasobu dostępnej pamięci współdzielonej przez bloki w ramach multiprocesora, gdzie są wykonywane.

W sprawozdaniu należy:

- uzasadnić teoretycznie wielkość użytej instancji problemu zapewniającej nasycenie obliczeniami,
- określić zbadane przypadki określone liczbą wyników obliczanych przez każdy wątek dla poszczególnych wielkości bloku wątków 16x16 i 32x32,
- określić postać i wynik testu poprawności wszystkich przeprowadzonych wariantów obliczeń, dla zapewnienia wiarygodności testu należy zadbać o niejednorodność danych, aby można było wykryć i poprawić błędy w organizacji dostępu do danych w trakcie przetwarzania,
- wyznaczyć prędkość obliczeń zależną od:
 - liczby wyników obliczanych przez wątek,
 - krotności wykorzystania danych znajdujących się w pamięci współdzielonej,
 - dla danych pobranych z pamięci współdzielonej faktu przechowywania /braku przechowywania w rejestrach danych użytych dla wielokrotnych obliczeń
 - wielkości bloku wątku.
- wyniki (miary efektywności) eksperymentów prezentowane w sprawozdaniu powinny umożliwić ocenę przyczyn różnic w prędkościach obliczeń dla różnych wersji kodu.

Sprawozdanie ocenione pozytywnie musi zawierać:

- część teoretyczną zawierającą rysunki dotyczące dostępu (odczyt, zapis) do danych w pamięci globalnej i pamięci współdzielonej przez poszczególne wątki bloku (ocena i zapewnienie efektywności transferu danych), powiązanie oceny z liniami kodu gdzie dostęp występuje,
- obliczenia teoretycznej wielkości (na podstawie wariantów kodu) parametru CGMA
- obliczenia intensywności arytmetycznej (iloraz liczby operacji arytmetycznych i liczby bajtów pobranych z RAM karty na podstawie pomiarów zdarzeń/ miar efektywności profilera)
- uzasadnienia dla spodziewanych, możliwych i zrealizowanych uruchomień kodów, informacje na temat ewentualnego braku powodzenia eksperymentu (komunikaty, sygnały o niepowodzeniu)
- uzasadnienia dla wielkości badanych instancji,
- uzasadnienia dla zastosowanych konfiguracji uruchomienia kodu.

Mile widziane elementy sprawozdania (wpływ na wysokość oceny)

- potwierdzenie przyczyn efektywności/ braku efektywności przetwarzania i dostępu do danych za pomocą zdarzeń profilera, na tej podstawie informacja o liczbie, jakości i typach dostępu do pamięci, zajętości multiprocesora, ograniczeniach wynikających z zasobów multiprocesora (rejstry, pamięć współdzielona, inne) dla zajętości.

Wyznaczony w ekursy termin oddawania projektu jest ostateczny. Przekroczenie terminu przy braku 50% punktów z pozostałych ocenianych elementów laboratorium powoduje ocenę niedostateczną w pierwszym terminie zaliczania przedmiotu. Z tego powodu proszę o wcześniejsze rozpoczęcie prac nad projektem aby niespodziewane wydarzenia nie stanowiły przeszkody dla terminowego oddania pełnego sprawozdania.

Przygotowująca projekt grupa omawia zakres wykonanych analiz, eksperymentów i ich wyniki w czasie 10 minut na ostatnich zajęciach laboratoryjnych.

Przygotowano 27.04.2026 v.26.0