Projekt I przetwarzanie równoległe 2025/26 SS, OpenMP, Vtune

Emilia Bonk 160108
Szymon Urban 160271

Wstęp.

- **Nazwa przedmiotu:** Laboratorium z przetwarzania równoległego
- **Autorzy:** Emilia Bonk (160108), Szymon Urban (160271)
- **Grupa dziekańska:** L09
- **Termin zajęć laboratoryjnych:** Wtorek 9:45-11:15
- **Termin oddania sprawozdania:** 5.05.2026
- **Wersja sprawozdania:** pierwsza
- **Opis zadania:** Celem ćwiczenia była analiza implementacji algorytmu Sita Eratostenesa w środowisku równoległym i sekwencyjnym z wykorzystaniem biblioteki OpenMP. Zadanie polegało na analizie i modyfikacji podanych kodów, z róznymi implementacjami algorytmu, a następnie porównaniu ich wydajności.
- **Adres e-mail:** emilia.bonk@student.put.poznan.pl, szymon.urban@student.put.poznan.pl

1 Informacje techniczne.

Parametr	**Wartość**
Model procesora	17th Gen Intel(R) Core(TM) i7-12700F
Liczba procesorów fizycznych	1
Liczba rdzeni	12 (8 Performance, 4 Efficient)
Liczba procesorów logicznych	20
Pamięć cache L1	1,0 MB
Pamięć cache L2	12,0 MB
Pamięć cache L3	25,0 MB
L1 data cache dla EFfCore	32 kB
L1 data cache dla PerfCore	48 kB
System operacyjny	Windows 10
Kompilator	Intel(R) oneAPI DPC++/C++ Compiler 2025.3.3
Wersja kompilatora	2025.3.3.20260319
Program testujący	Intel VTune Profiler 2026.0.0

Tablica 1: Informacje techniczne dotyczące środowiska testowego

2 Prezentacja i analiza kodów.

K1 - Algorytm sekwencyjny oparty na próbnych dzieleniach.

Oznaczenie skrótowe: k1

Algorytm sekwencyjny oparty na metodzie dzielenia próbnego. Najpierw wyznacza liczby pierwsze w zakresie do $\sqrt{n}$, a następnie szeregowo sprawdza podzielność każdej liczby $i \in [m, n]$ przez te dzielniki. Koszt obliczeń jest zmienny – najniższy dla liczb parzystych, najwyższy dla liczb pierwszych.

```
int calculate(int n, int m){
        bool* result = (bool*)malloc((n - m + 1) * sizeof(bool));
        memset(result, true, (n - m + 1) * sizeof(bool));
        int prime_counter = 0;

        bool* primeArray = (bool*)malloc((sqrt(n) + 1) * sizeof(bool));
        memset(primeArray, true, (sqrt(n) + 1) * sizeof(bool));

        if (m <= 0 && n >= 0) result[0 - m] = false;
        if (m <= 1 && n >= 1) result[1 - m] = false;

        for (int i = 2; i * i <= n; i++) {
                for (int j = 2; j * j <= i; j++) {
                        if (primeArray[j] == true && i % j == 0) {
                                primeArray[i] = false;
                                break;
                        }
                }
        }
        for (int i = m; i <= n; i++){
                for (int j = 2; j * j <= i; j++){
                        if (primeArray[j] == true && i % j == 0) {
                                result[i - m] = false;
                                break;
                        }
                }
                if(result[i-m] == true){
                        prime_counter++;
                }
        }
        free(result);
        free(primeArray);

        return prime_counter;
}
```

Listing 1: Kod programu k1.cpp

K2 - Liczby pierwsze wyznaczane równolegle przez dzielenie w zakresie <m,n>.

Oznaczenie skrótowe: k2

Wariant równoległy wykorzystujący dzielenie próbne z dyrektywą `schedule(guided)`. Zastosowanie malejących paczek zadań pozwala na efektywne zrównoważenie obciążenia procesora, niwelując różnice w czasie sprawdzania małych i dużych liczb. Brak wyścigów przy zapisie do tablicy wyników.

```
int calculate(int n, int m){
        int prime_counter = 0;

        //...liczenie sita (PrimeArray) jak w kodzie k1
        #pragma omp parallel
        {
        #pragma omp for schedule(guided) reduction(+:prime_counter)
        for (int i = m; i <= n; i++){
                for (int j = 2; j * j <= i; j++){
                        if (primeArray[j] == true && i % j == 0) {
                                result[i - m] = false;
                                break;
                        }
                }
                if(result[i-m] == true){
                        prime_counter++;
                }
        }
        }
        free(result);
        free(primeArray);

        return prime_counter;
}
```

Listing 2: Kod programu k2.cpp

K3 - Sito sekwencyjne bez lokalności dostępu do danych.

Oznaczenie skrótowe: k3

Sito Eratostenesa realizowane sekwencyjnie. Zamiast dzielenia, algorytm wykreśla wielokrotności liczb pierwszych $i \leq \sqrt{n}$ w całym zakresie $[m, n]$. Charakteryzuje się niską złożonością obliczeniową $O(n \log \log n)$, ale ograniczoną lokalnością danych przy skokowym dostępie do tablicy wyników.

```
int calculate(int n, int m){
        //...liczenie sita jak we wczesniejszych kodach

        for (int i = 2; i*i <= n; i++){
                if (primeArray[i]) {
                        int firstMultiple = (m / i);
                        if (firstMultiple <= 1) {
                                firstMultiple = i + i;
                        } else if (m % i) {
                                firstMultiple = (firstMultiple * i) + i;
                        } else {
                                firstMultiple = (firstMultiple * i);
                        }
                        for (int j = firstMultiple; j <= n; j+=i) {
                                result[j-m] = false;
                        }
                }
        }
        if (m <= 0 && n >= 0) result[0 - m] = false;
        if (m <= 1 && n >= 1) result[1 - m] = false;

        for (int i = m; i <= n; i++) {
        if (result[i - m]) prime_counter++;
        }

        free(result);
        free(primeArray);

        return prime_counter;
}
```

Listing 3: Kod programu k3.cpp

K3a - Sito sekwencyjne z lokalnością dostępu do danych.

Oznaczenie skrótowe: k3a

Sekwencyjne sito segmentowe zoptymalizowane pod kątem lokalności danych. Zakres $[m, n]$ dzielony jest na bloki mieszczące się w pamięci cache L1/L2. Przetwarzanie blokowe znacząco przyspiesza operacje zapisu do tablicy wyników poprzez redukcję pudeł cache.

```
int calculate(int n, int m){
    //...alokacja pamieci i liczenie PrimeArray tak samo jak w kodzie k3

    int blockSize = 32768;
    int numberOfBlocks = (n - m) / blockSize;
    if ((n - m) % blockSize != 0) {
        numberOfBlocks++;
    }

    for (int i = 0; i < numberOfBlocks; i++) {
        int low = m + i * blockSize;
        int high = low + blockSize - 1;
        if (high > n) {
            high = n;
        }

        for (int j = 2; j * j <= high; j++) {
            if (primeArray[j] == true) {
                int firstMultiple = (low / j);
                if (firstMultiple <= 1) {
                    firstMultiple = j + j;
                } else if (low % j) {
                    firstMultiple = (firstMultiple * j) + j;
                }  else {
                    firstMultiple = (firstMultiple * j);
                }
                for (int k = firstMultiple; k <= high; k += j) {
                    result[k - m] = false;
                }
            }
        }
    }

        //...zliczanie prime_count i zwalnianie pamieci jak w kodzie k3
}
```

Listing 4: Kod programu k3a.cpp

K4 - Sito równoległe funkcyjne bez lokalności dostępu do danych.

Oznaczenie skrótowe: k4

Równoległe sito z podziałem funkcyjnym (`schedule(dynamic, 1)`). Wątki pobierają kolejne liczby pierwsze i wykreślają ich wielokrotności w całym zakresie wyników. Występuje zjawisko `false sharing` oraz bezpieczne wyścigi przy zapisie tej samej wartości logicznej pod ten sam indeks.

```
int calculate(int n, int m){
        //...alokacja pamieci i lizcenie PrimeArray jak wczesniej

        int limit = sqrt(n);
        #pragma omp parallel for schedule(dynamic, 1)
        for (int i = 2; i <= limit; i++){
                if (primeArray[i]) {
                        int firstMultiple = (m / i);
                        if (firstMultiple <= 1) {
                                firstMultiple = i + i;
                        } else if (m % i){
                                firstMultiple = (firstMultiple * i) + i;
                        } else {
                                firstMultiple = (firstMultiple * i);
                        }
                        for (int j = firstMultiple; j <= n; j+=i) {
                                result[j-m] = false;
                        }
                }
        }

        //zliczanie prime_count i zwalnianie pamieci jak wczesniej
}
```

Listing 5: Kod programu k4.cpp

K4a - Sito równoległe funkcyjne bez lokalności dostępu do danych z usunięciem redundancji zapisów.

Oznaczenie skrótowe: k4a

Modyfikacja algorytmu K4 wprowadzająca warunkowy zapis do tablicy wyników (`if (result[j-m])`). Ma to na celu ograniczenie liczby operacji zapisu i związanych z nimi konfliktów w pamięci cache, co poprawia wydajność przy zachowaniu podziału funkcyjnego.

```
int calculate(int n, int m){
        //...alokacja pamieci i zliczanie PrimeArray jak wczesniej

        int limit = sqrt(n);
        #pragma omp parallel for schedule(dynamic, 1)
        for (int i = 2; i <= limit; i++){
                if (primeArray[i]) {
                        int firstMultiple = (m / i);
                        if (firstMultiple <= 1) {
                                firstMultiple = i + i;
                        } else if (m % i){
                                firstMultiple = (firstMultiple * i) + i;
                        } else {
                                firstMultiple = (firstMultiple * i);
                        }
                        for (int j = firstMultiple; j <= n; j+=i) {
                                if (result[j-m]) result[j-m] = false;
                        }
                }
        }

        //zliczanie prime_counter i zwalnianie pamieci jak w k4
}
```

Listing 6: Kod programu k4a.cpp

K5 - Sito równoległe domenowe z lokalnością dostępu do danych

Oznaczenie skrótowe: k5

Równoległe sito segmentowe z podziałem domenowym. Każdy wątek przetwarza niezależne bloki danych mieszczące się w cache, co eliminuje `false sharing` i wyścigi. Choć wydawałoby się, że `schedule(static)` minimalizuje narzut synchronizacji przy wyrównanym obciążeniu bloków, to jednak znacznie lepszy performormance zaobserwowaliśmy przy `schedule(guided)`.

```
int calculate(m, n){
        //...alokacja pamieci i liczenie PrimeArray jak wczesniej

        int blockSize = 32768;
        int numberOfBlocks = (n - m) / blockSize + ((n - m) % blockSize != 0);

        #pragma omp parallel for schedule(guided)
        for (int i = 0; i < numberOfBlocks; i++) {
                int low = m + i * blockSize;
                int high = low + blockSize - 1;
                if (high > n) high = n;

                for (int j = 2; j * j <= high; j++) {
                        if (primeArray[j]) {
                                int firstMultiple = (low / j) * j;
                                if (firstMultiple < low) firstMultiple += j;
                                if (firstMultiple == j) firstMultiple += j;

                                for (int k = firstMultiple; k <= high; k += j) {
                                        result[k - m] = false;
                                }
                        }
                }
        }

        //zliczanie prime_counter i zwalnianie pamieci jak wczesniej
}
```

Listing 7: Kod programu k5.cpp

3 Prezentacja wyników i omówienie przebiegu eksperymentu.

Zasady pracy z oprogramowaniem VTune.

Intel VTune Profiler to narzędzie do profilowania wydajności aplikacji na platformach Intel. W ramach przeprowadzonego eksperymentu wykorzystano tryb **Microarchitecture Exploration**, który umożliwia szczegółową analizę wykorzystania mikroarchitektury procesora poprzez zbieranie zdarzeń sprzętowych (hardware performance counters). Skorzystano również dla kodów równoległych z testu **Threading**, który pozwala na analizę efektywnego wykorzystania CPU oraz podziału czasu pracy między sekcję równoległą a sekwencyjną. W ramach analizy wariantów kodów k3, k3a, k4 i k4a został też przeprowadzony test **Memory Access**, który pozwolił na analizę dostępów do pamięci.

Porównanie podstawowych parametrów wywołania dla kodów k1-k5.

Porównania zostały wykonane dla kodów przedstawionych w poprzedniej sekcji, z tymi samymi schedulingami i rozmiarami bloków na zakresie liczb od 1 do 100 milionów. Są one wynikiem testu **Microarchitecture Exploration**.

	k1	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
Elapsed Time [s]	23.750	2.394	0.660	0.130	0.381	0.296	0.060
Prędkość przetwarzania [mln l. pierwszych/s]	4.210	2.406	14.394	35.714	15.121	19.464	96.024
Instructions retired [mld]	405,744	405,599	0,515	0,777	2,179	1,501	1,702
Clockticks [miliardów tików]	105,112	166,746	2,914	0,566	19,808	14,777	1,995
Effective PCU	7.7%	68.9%	4.7%	7.1%	42.4%	51.5%	23.4%
Badania kodów równoległych	**k1**	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
Przyspieszenie względem k3a	-	0.05	-	-	0.34	0.43	2.17
Efektywność [Acc/Cores]	-	0.004	-	-	0.028	0.036	0.180

Tablica 2: Porównanie podstawowych parametrów wywołania dla kodów k1-k5.

Performance Cores	**k1**	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
Retiring	66.0%	83.5%	1.2%	0.0%	1.1%	4.5%	25.0%
Front End Bound	11.4%	13.8%	0.0%	3.1%	3.6%	20.0%	25.0%
Back End Bound	3.3%	1.7%	100.0%	0.0%	78.7%	58.0%	41.7%
Memory Bound	0.2%	0.2%	100.0%	0.0%	67.4%	42.6%	16.7%
Core Bound	3.1%	1.5%	0.0%	0.0%	11.4%	15.3%	25.0%
Efficient Cores	**k1**	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
Retiring	0.0%	42.3%	0.0%	0.0%	3.0%	0.7%	0.0%
Front End Bound	0.0%	5.0%	0.0%	0.0%	1.3%	3.8%	0.0%
Back End Bound	4.1%	11.5%	0.0%	0.0%	90.8%	34.8%	97.4%
Memory Bound	0.0%	0.2%	0.0%	0.0%	53.0%	34.8%	18.8%
Core Bound	4.1%	11.3%	0.0%	0.0%	37.8%	0.0%	78.6%

Tablica 3: Wyniki analizy przyczyn ograniczeń wydajności dla kodów k1-k5 z podziałem na Performance i Efficient Cores.

Porównanie działań kodów dla różnych zakresów liczb.

W ramach tego eksperymentu zmierzyliśmy Ellapsed Time dla kodów k1-k5 dla trzech różnych zakresów liczb: <2; max>, <max/2; max> oraz <2; max/2>, gdzie `max` to 10^8.

Zakres liczb	k1	k2	k3	k3a	k4	k4a	k5
<2; max>	23.750 s	2.394 s	0.660 s	0.130 s	0.381 s	0.296 s	0.060 s
<max/2; max>	16.671 s	3.852 s	0.303 s	0.069 s	0.279 s	0.122 s	0.038 s
<2; max/2>	7.116 s	2.450 s	0.282 s	0.065 s	0.225 s	0.117 s	0.050 s

Tablica 4: Porównanie prędkości działania dla różnych zakresów liczb w kodach k1-k5.

Porównanie zakresów ujawnia różne zachowania algorytmów w zależności od położenia zakresu. Dla **k1 i k2** (dzielenie próbne) czas silnie zależy od gęstości liczb pierwszych i wartości sprawdzanych liczb. Zakres $\langle \max/2; \max \rangle$ trwa dłużej niż $\langle 2; \max/2 \rangle$, ponieważ duże liczby wymagają sprawdzenia więcej dzielników (do $\sqrt{i}$). Dla **k3, k3a, k4, k4a, k5** (sito) czas nie zależy od wartości sprawdzanych liczb, lecz przede wszystkim od **rozmiaru zakresu**. Złożoność segmentowego sita Eratostenesa dla zakresu $\langle m, n \rangle$ wynosi $O(L \cdot \log \log n)$, gdzie $L = n - m$ to rozmiar zakresu, a n to górna granica. Ponieważ $\log \log n$ zmienia się bardzo wolno i jest niemal identyczne dla obu półzakresów, czas przetwarzania jest w przybliżeniu proporcjonalny do L — stąd oba półzakresy mają zbliżone czasy, mniejsze niż pełny zakres.

Badanie wpływu różnych szeregowań dla czasu przetwarzania kodów k2, k4, k4a i k5.

Test został przeprowadzony na trybie **Microarchitecture Exploration**, a wyniki Ellapsed Time zostały umieszczone w Tablicy 5. Porównano trzy różne szeregowania: `schedule(static)`, `schedule(dynamic)` i `schedule(guided)`.

Schedule	k2	k4	k4a	k5
static	6.339 s	0.551 s	0.541 s	0.151 s
dynamic	2.475 s	0.296 s	0.381 s	0.080 s
guided	2.394 s	0.558 s	0.727 s	0.060 s

Tablica 5: Wpływy szeregowań na czas przetwarzania kodów równoległych.

Dla **k2** (dzielenie próbne) `schedule(guided)` (2,394 s) i `schedule(dynamic)` (2,475 s) są zbliżone i znacznie lepsze od `schedule(static)` (6,339 s). Wynika to z nierównomiernego kosztu sprawdzania poszczególnych liczb — statyczny podział przydziela jednym wątkom wyłącznie duże liczby (droższe), innym — małe (tańsze), powodując silne niezrównoważenie.

Dla **k4 i k4a** (sito funkcyjne) `schedule(dynamic)` okazuje się lepszy od `schedule(guided)`, gdyż zadania (kolejne liczby pierwsze do wykreślenia) mają bardzo zróżnicowany koszt — mała liczba pierwsza (np. 2) generuje wiele wielokrotności, duża (np. 9999991) — nieliczne. Dynamiczny przydział po jednym zadaniu na raz najlepiej to wyrównuje.

Dla **k5** (sito domenowe) `schedule(guided)` (0,060 s) jest najlepsze, bo bloki danych mają zbliżony koszt przetwarzania, a malejące paczki zadań redukują narzut synchronizacji przy końcu pętli, kiedy wątki kończą pracę w różnym czasie.

Porównanie wyników przetwarzania kodów k3 i k3a.

W celu głębszej analizy przyczyn różnicy w czasie przetwarzania między k3 (0,660 s) a k3a (0,130 s) przeprowadzono dodatkowy eksperyment z wykorzystaniem testu **Memory Access**. Wyniki przedstawiono na Rysunkach 1 i 2 oraz w Tablicy 6.

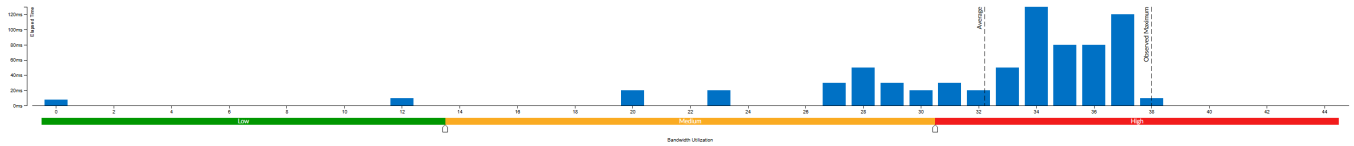

Rysunek 1: Wynik testu Memory Access BandwitdhHistogram dla kodu k3.

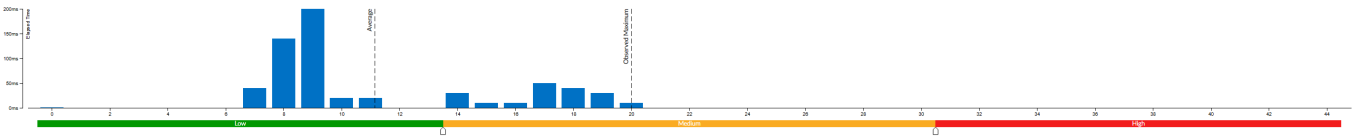

Rysunek 2: Wynik testu Memory Access BandwitdhHistogram dla kodu k3a.

Możemy zobaczyć, że średnia przepustowość k3 jest praktycznie 3 razy większa niż k3a. Są to około 32 GB/s, dochodząc nawet do 38GB/s. W kodzie k3 średnia wartość to już 11GB/s, ilość danych przechodzących przez magistralę jest znacznie mniejsza. Wynika to z naszej zmiany w kodzie k3a - zmieniamy pojedynczą iterację na przetwarzającą blok, a nie konkretną liczbę, dzięki czemu aktywny rozmiar tablicy mieści się w L1. W k3 zaś wykreślamy dla każdej iteracji liczby na całym zakresie, przez co każdy zapis trafia w odległe od siebie miejsca w pamięci.

	k3	**k3a**
P-Core L1 Bound	0.0%	0.0%
P-Core L2 Bound	1.1%	0.0%
P-Core L3 Bound	1.5%	0.0%
P-Core Store Bound	82.6%	0.0%
E-Core L1 Bound	0.0%	1.6%
E-Core L2 Bound	0.0%	0.0%
E-Core L3 Bound	0.0%	0.0%

Tablica 6: Porównanie czasów oczekiwania Memory Bound dla kodów k3 i k3a

Aby lepiej zrozumieć problem przyjrzeliśmy się również przyczynom ograniczeń wydajności dla obu kodów. Możemy zobaczyć, że k3 jest w 82,6% ograniczony przez oczekiwanie na przepełniony store buffer. Jest on więc dla naszego kodu wąskim gardłem — liczba żądań zapisu przerasta pojemność bufora zapisu procesora. Możemy też zauważyć że w kodzie k3 ograniczenia pamięci występują na L2 i L3; wynika to z tego że pętla wykreślająca wielokrotności przechodzi przez całą tablicę `result` o rozmiarze 100 mln elementów. Tablica ta nie mieści się w L1 ani L2 pojedynczego rdzenia, więc przy każdym dostępie procesor musi załadować odpowiednią linię cache z L2 lub L3.

W kodzie k3a obraz jest zupełnie odmienny. Przetwarzanie blokowe sprawia że aktywny obszar tablicy wynosi zawsze 32 kB i powinien mieścić się w L1 zarówno E-core jak i L1 P-core. Dla każdego bloku wszystkie dzielniki $i \leq \sqrt{\text{high}}$ są przetwarzane zanim algorytm przejdzie dalej - linie cache pozostają w L1 przez cały czas przetwarzania bloku i są wielokrotnie wykorzystywane. Stąd zerowe L2 Bound, L3 Bound i Store Bound - jedyne ograniczenie występuje na E-Core L1 Bound, następuje lekkie przepełnienie na pierwszej pamięci cache, czego jednak można było się spodziewać, jest ona mniejsza niż L1 P-core, mając dokładnie 32kB zamiast 48kB jak w wypadku P-Core.

Analiza wyników przetwarzania kodów k4 i k4a.

W tym eksperymencie poddaliśmy teście **Memory Access** kody k4 i k4a, aby zobaczyć jak dodanie warunku `if result[j-m]` wpływa na ograniczenia związane z pamięcią, i tym samym czas wykonania kodu. Wyniki przedstawiono w Tablicy 7.

	k4	**k4a**
P-Core Memory Bound	81.4%	28.3%
P-Core L1 Bound	2.9%	7.3%
P-Core L2 Bound	1.3%	0.8%
P-Core L3 Bound	3.6%	4.6%
P-Core Store Bound	72.3%	0.3%
E-Core Memory Bound	77.8%	58.1%
E-Core L1 Bound	0.6%	1.5%
E-Core L2 Bound	0.0%	0.2%
E-Core L3 Bound	0.0%	0.3%
Loads	94,902,847	389,711,691
Stores	241,807,254	155,704,671

Tablica 7: Porównanie czasów oczekiwania Memory Bound dla kodów k4 i k4a

Kod **k4** na obu rodzajach rdzeni uzyskał wyższe Memory Bound niż **k4a**. Na rdzeniu Performance możemy ponownie jak w wypadku kodu **k3** zobaczyć wysoki Store Bound (72.3%), który wiąże się z dużą liczbą operacji zapisu do tablicy `result` oraz ponownie przemieszczaniu się po całej tablicy. Stosunek Loads do Stores dla k4 wynosi około 1:2, odbywa się więcej zapisów niż odczytów, wielokrotnie bowiem nadpisujemy wartość `false` pod ten sam indeks. Dodanie warunku `if (result[j-m])` w kodzie k4a redukuje liczbę zapisów, zmieniając proporcje Loads/Stores do około 2.5:1, znacząco redukuje to Store Bound i poprawia wyniki na Memory Bound. Nie usuwa jednak problemu w całości, wciąż występują ograniczenia na pamięciach cache L1, L2, i L3. Dodanie warunku tworzy nowy koszt w postaci dodatkowych odczytów, sprawiając, że choć udało nam się zredukować Store Bound, kod wcale nie jest wolny od ograniczeń związanych z pamięcią i wykazuje się jedynie niewielką poprawą czasu wykonania.

Wyniki eksperymentu wyznaczania wielkości bloku dla kodów k3a i k5.

Aby wyznaczyć optymalną wielkość bloku dla kodów k3a i k5 napisaliśmy eksperyment, który wywoływał te kody dla standardowego zakres <2; max> z różnymi rozmiarami bloków od 16B do ilości liczb w zakresie z krokiem x2. Poniżej znajduje się część tabeli wynikowej, w której na środku znajduje się nasze poszukiwane optimum.

Blocksize	**k3a**	**k5**
4096	0.382 s	0.061 s
8192	0.229 s	0.040 s
16384	0.145 s	0.036 s
32768	0.107 s	0.030 s
65536	0.120 s	0.031 s
131072	0.121 s	0.039 s
262144	0.126 s	0.035 s
524288	0.128 s	0.040 s

Tablica 8: Wpływ rozmiaru bloku na czas przetwarzania kodów k3a i k5.

Optymalny rozmiar bloku wynosi **32768 elementów** (32 kB) dla obu kodów k3a i k5. Jest to wynik, którego możemy się spodziewać po sprawdzeniu parametrów procesora: choć posiada on ogółem 1 MB na pamięci L1, podzielona jest ona między 12 rdzeni, z czego 8 to rdzenie Performance z 48 kB cache L1, a pozostałe 4 to rdzenie Efficient z 32 kB cache L1. Z tych względów rozmiar bloku 32 kB będzie optymalny, będzie mieścił się w cache L1 obu typów rdzeni, jednocześnie będąc na tyle dużym aby zredukować niepotrzebny narzut związany z pobieraniem mniejszych ale większej liczby bloków z pamięci głównej do cache. Większy blok nie mieściłby się już zaś w L1, zmuszając do przenoszenia danych do wolniejszej pamięci L2, co ponownie zaczyna skutkować spadkiem wydajności.

Dodatkowy eksperyment: zwiększenia zakresu liczb do 1 miliarda.

W czasie przetwarzania kodów równoległych w standardowym zakresie <2;100 mln> zauważyliśmy, że czasy przetwarzania są bardzo krótkie, co utrudnia dokładną analizę wydajności. Dlatego zdecydowaliśmy się na dodatkowy eksperyment, w którym zwiększyliśmy zakres liczb do 1 miliarda. Poniżej przedstawiamy porównania wyników testu **Threading** dla kodu równoległego k4.

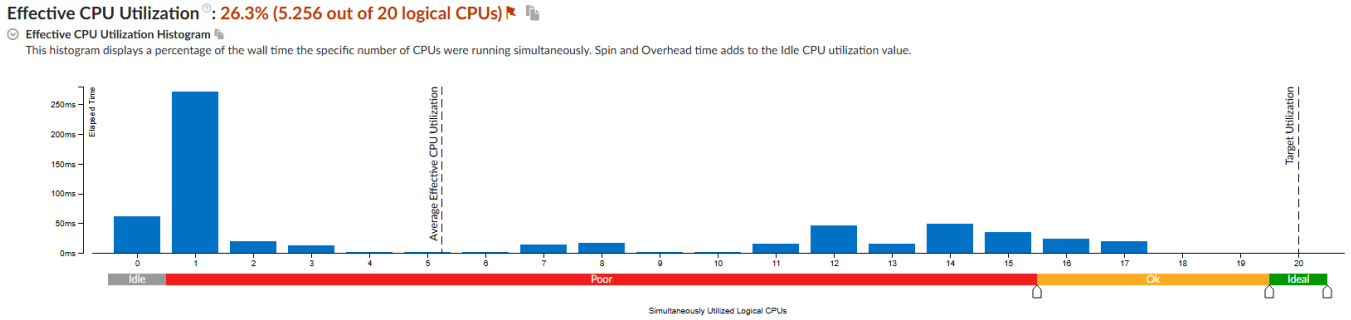

Rysunek 3: Wynik testu threading k4 dla zakresu <2; 100 mln>.

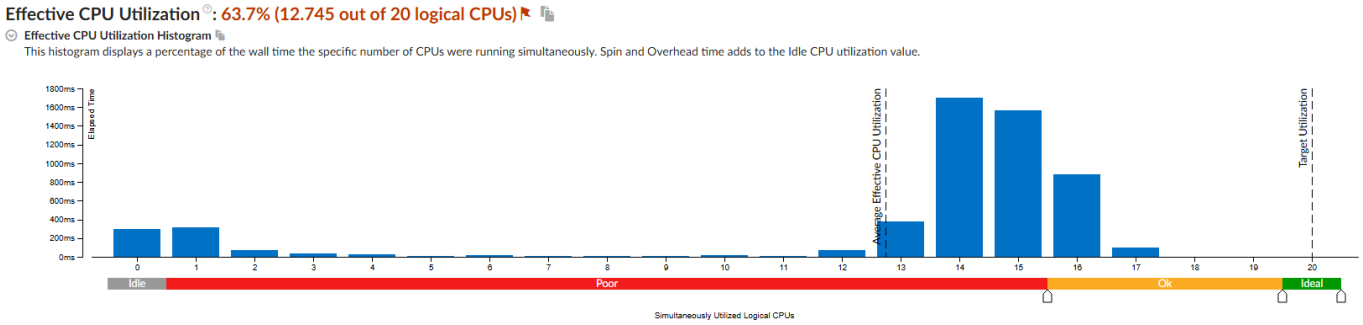

Rysunek 4: Wynik testu threading k4 dla zakresu <2; 1 mld>.

Pierwsze co rzuca się przy analizie wyżej przedstawionych wykresów to znaczny wzrost efektywności CPU z 26.3% na 63.7% po zwiększeniu zakresu. Czas spędzony na pracy 0 lub 1 wątku pozostaje w obu wypadkach taki sam: w sumie około 0.6 s. Cały dodatkowy czas wykonania to czas spędzony w sekcji równoległej, który wzrósł z 0.267 s na 4.871 s. Z wykresu widać że najwięcej czasu kod wykonuje jednocześnie 14 wątków, a nie 1 jak w przypadku rysunku 1. Podobne wyniki zaobserwowaliśmy dla reszty równoległych kodów. Widzimy więc, że niska wydajność kodów nie wynika z ich złej implementacji, a zbyt małego zakresu liczb w teście, który nie pozwalał na efektywne wykorzystanie potencjału równoległego procesora.

4 Wnioski.

Na podstawie przeprowadzonych eksperymentów oraz szczegółowej analizy profilowania w narzędziu Intel VTune, sformułowano następujące wnioski:

1. **Porównanie jakości i wydajności rozwiązań:** Najlepszym rozwiązaniem pod względem prędkości przetwarzania okazał się wariant **k5** (równoległe sito domenowe z blokowaniem), osiągając czas 0,060 s dla instancji 10^8. Jest on ponad **395 razy szybszy** od najgorszego wariantu **k1** (23,750 s). Metody oparte na sicie Eratostenesa (k3-k5) deklasują metody dzielenia próbnego (k1-k2) ze względu na znacznie niższą złożoność obliczeniową i zastąpienie kosztownych operacji modulo prostym dodawaniem i adresowaniem pamięci.

2. **Wykorzystanie struktur procesora i eliminacja wąskich gardeł:**

   - **Lokalność danych (k3 vs k3a):** Wariant k3 jest drastycznie ograniczony przez przepełnienie buforów zapisu (**82,6% Store Bound**, Tablica 6) z powodu skokowego dostępu do pamięci w pełnym zakresie. Zastosowanie blokowania w k3a pozwoliło na utrzymanie danych w cache L1, co całkowicie wyeliminowało to wąskie gardło i skróciło czas obliczeń ponad 5-krotnie.
   - **Redukcja redundancji zapisów (k4 vs k4a):** Wprowadzenie warunku `if (result[j-m])` w k4a pozwoliło zredukować `Store Bound` z 72,3% do 0,3% (Tablica 7). Choć poprawiło to czas wykonania, metoda ta wciąż ustępuje k5, ponieważ brak blokowania domenowego powoduje wysokie opóźnienia na magistrali pamięci (`Memory Bound`).

3. **Analiza architektury hybrydowej (Performance i Efficient Cores):** Zastosowany procesor i7-12700F posiada niejednorodną strukturę (8 rdzeni P i 4 rdzenie E), co niesie za sobą konkretne konsekwencje dla wydajności:

   - **Konsekwencje wydajnościowe:** Rdzenie Performance są znacznie efektywniejsze – w teście k2 osiągają wskaźnik `Retiring` na poziomie 83,5%, podczas gdy rdzenie Efficient jedynie 42,3% (Tablica 4). Oznacza to, że rdzenie P wykonują dwa razy więcej użytecznej pracy w tym samym czasie.
   - **Problem Load Imbalance:** Różna moc obliczeniowa rdzeni sprawia, że przy domyślnym szeregowaniu `static` szybsze rdzenie P kończą pracę wcześniej i bezczynnie czekają na rdzenie E. Rozwiązaniem okazało się stosowanie `schedule(guided)` lub `dynamic`, które pozwalają na dynamiczne przydzielanie zadań w miarę zwalniania się zasobów, co pomaga "ukryć" mniejszą wydajność rdzeni E.
   - **Ograniczenia Cache L1:** Rdzenie P mają 48 kB L1, natomiast rdzenie E tylko 32 kB. Eksperyment wykazujący optimum bloku przy **32 kB** (Tablica 8) potwierdza, że w architekturze hybrydowej należy optymalizować kod pod "najsłabsze ogniwo" – stąd wybór bloku 32 kB. Użycie większego bloku (np. 48 kB) spowolniłoby rdzenie E, zmuszając je do częstego sięgania do wolniejszego cache L2, co zniwelowałoby zysk z ich pracy.

4. **Jakość zrównoleglenia i skalowalność:** Dla standardowej instancji 10^8 efektywność zrównoleglenia wariantu k5 wynosi jedynie 0,18 (Tablica 2). Główną przyczyną jest bardzo krótki czas obliczeń (0,06 s), w którym narzut na stworzenie i synchronizację 20 wątków OpenMP jest porównywalny z samym czasem pracy. Dodatkowy eksperyment dla 10^9 (Rys. 4) wykazał wzrost wykorzystania procesora do **63,7%**. Pokazuje to, że pełne wykorzystanie 12 rdzeni (20 wątków) wymaga dostatecznie dużych instancji problemu, aby zysk z pracy równoległej przeważył nad kosztem zarządzania wątkami.

5. **Analiza szeregowania (Scheduling):** Wybór szeregowania zależy od charakteru algorytmu. Dla **k2** (dzielenie próbne) i **k5** (sito domenowe) najlepszy okazał się `guided`, który minimalizuje narzut synchronizacji przy jednoczesnym dbaniu o *load balancing*. Dla **k4/k4a** (sito funkcyjne) lepszy jest `dynamic`, ponieważ koszt wykreślania dla różnych liczb pierwszych jest skrajnie różny (małe liczby pierwsze generują tysiące razy więcej zapisów niż duże).

6. **Wnioski końcowe:** Najbardziej efektywnym podejściem jest połączenie **segmentowego sita Eratostenesa (k5)** z dynamicznym balansem obciążenia. Kluczem do sukcesu na nowoczesnych procesorach hybrydowych jest:

   - Dopasowanie struktur danych (bloków) do mniejszej pamięci cache L1 (rdzeni E).
   - Zastosowanie elastycznego szeregowania zadań, które zapobiega przestojom szybszych rdzeni P.
   - Minimalizacja operacji zapisu poprzez warunkowe sprawdzanie wartości lub blokowanie domenowe, co odciąża Store Buffer.