Projekt I przetwarzanie równoległe 2025/26 SS, OpenMP, Vtune

Emilia Bonk 160108
Szymon Urban 160271

Wstęp.

- **Nazwa przedmiotu:** Laboratorium z przetwarzania równoległego
- **Autorzy:** Emilia Bonk (160108), Szymon Urban (160271)
- **Grupa dziekańska:** L09
- **Termin zajęć laboratoryjnych:** Wtorek 9:45-11:15
- **Termin oddania sprawozdania:** 5.05.2026
- **Wersja sprawozdania:** pierwsza
- **Opis zadania:** Celem ćwiczenia była analiza implementacji algorytmu Sita Eratostenesa w środowisku równoległym i sekwencyjnym z wykorzystaniem biblioteki OpenMP. Zadanie polegało na analizie i modyfikacji podanych kodów, z róznymi implementacjami algorytmu, a następnie porównaniu ich wydajności.
- **Adres e-mail:** emilia.bonk@student.put.poznan.pl, szymon.urban@student.put.poznan.pl

1 Informacje techniczne.

Parametr	**Wartość**
Model procesora	17th Gen Intel(R) Core(TM) i7-12700F
Liczba procesorów fizycznych	1
Liczba rdzeni	12 (8 Performance, 4 Efficient)
Liczba procesorów logicznych	20
Pamięć cache L1	1,0 MB
Pamięć cache L2	12,0 MB
Pamięć cache L3	25,0 MB
L1 data cache dla EFfCore	32 kB
L1 data cache dla PerfCore	48 kB
System operacyjny	Windows 10
Kompilator	Intel(R) oneAPI DPC++/C++ Compiler 2025.3.3
Wersja kompilatora	2025.3.3.20260319
Program testujący	Intel VTune Profiler 2026.0.0

Tablica 1: Informacje techniczne dotyczące środowiska testowego

2 Prezentacja i analiza kodów.

K1 - Algorytm sekwencyjny oparty na próbnych dzieleniach.

Oznaczenie skrótowe: SEQ-DIV-BASIC

Algorytm sekwencyjny oparty na metodzie dzielenia próbnego. Najpierw wyznacza liczby pierwsze w zakresie do $\sqrt{n}$, a następnie szeregowo sprawdza podzielność każdej liczby $i \in [m, n]$ przez te dzielniki. Koszt obliczeń jest zmienny – najniższy dla liczb parzystych, najwyższy dla liczb pierwszych.

```
int calculate(int n, int m){
        bool* result = (bool*)malloc((n - m + 1) * sizeof(bool));
        memset(result, true, (n - m + 1) * sizeof(bool));
        int prime_counter = 0;

        bool* primeArray = (bool*)malloc((sqrt(n) + 1) * sizeof(bool));
        memset(primeArray, true, (sqrt(n) + 1) * sizeof(bool));

        if (m <= 0 && n >= 0) result[0 - m] = false;
        if (m <= 1 && n >= 1) result[1 - m] = false;

        for (int i = 2; i * i <= n; i++) {
                for (int j = 2; j * j <= i; j++) {
                        if (primeArray[j] == true && i % j == 0) {
                                primeArray[i] = false;
                                break;
                        }
                }
        }
        for (int i = m; i <= n; i++){
                for (int j = 2; j * j <= i; j++){
                        if (primeArray[j] == true && i % j == 0) {
                                result[i - m] = false;
                                break;
                        }
                }
                if(result[i-m] == true){
                        prime_counter++;
                }
        }
        free(result);
        free(primeArray);

        return prime_counter;
}
```

Listing 1: Kod programu k1.cpp

K2 - Liczby pierwsze wyznaczane równolegle przez dzielenie w zakresie <m,n>.

Oznaczenie skrótowe: PAR-DIV-GUIDED

Wariant równoległy wykorzystujący dzielenie próbne z dyrektywą `schedule(guided)`. Zastosowanie malejących paczek zadań pozwala na efektywne zrównoważenie obciążenia procesora, niwelując różnice w czasie sprawdzania małych i dużych liczb. Brak wyścigów przy zapisie do tablicy wyników.

```
int calculate(int n, int m){
        int prime_counter = 0;

        //...liczenie sita (PrimeArray) jak w kodzie k1
        #pragma omp parallel
        {
        #pragma omp for schedule(guided) reduction(+:prime_counter)
        for (int i = m; i <= n; i++){
                for (int j = 2; j * j <= i; j++){
                        if (primeArray[j] == true && i % j == 0) {
                                result[i - m] = false;
                                break;
                        }
                }
                if(result[i-m] == true){
                        prime_counter++;
                }
        }
        }
        free(result);
        free(primeArray);

        return prime_counter;
}
```

Listing 2: Kod programu k2.cpp

K3 - Sito sekwencyjne bez lokalności dostępu do danych.

Oznaczenie skrótowe: SEQ-SIEVE-NL

Sito Eratostenesa realizowane sekwencyjnie. Zamiast dzielenia, algorytm wykreśla wielokrotności liczb pierwszych $i \leq \sqrt{n}$ w całym zakresie $[m, n]$. Charakteryzuje się niską złożonością obliczeniową $O(n \log \log n)$, ale ograniczoną lokalnością danych przy skokowym dostępie do tablicy wyników.

```
int calculate(int n, int m){
        //...liczenie sita jak we wczesniejszych kodach

        for (int i = 2; i*i <= n; i++){
                if (primeArray[i]) {
                        int firstMultiple = (m / i);
                        if (firstMultiple <= 1) {
                                firstMultiple = i + i;
                        } else if (m % i) {
                                firstMultiple = (firstMultiple * i) + i;
                        } else {
                                firstMultiple = (firstMultiple * i);
                        }
                        for (int j = firstMultiple; j <= n; j+=i) {
                                result[j-m] = false;
                        }
                }
        }
        if (m <= 0 && n >= 0) result[0 - m] = false;
        if (m <= 1 && n >= 1) result[1 - m] = false;

        for (int i = m; i <= n; i++) {
        if (result[i - m]) prime_counter++;
        }

        free(result);
        free(primeArray);

        return prime_counter;
}
```

Listing 3: Kod programu k3.cpp

K3a - Sito sekwencyjne z lokalnością dostępu do danych.

Oznaczenie skrótowe: SEQ-SIEVE-LL

Sekwencyjne sito segmentowe zoptymalizowane pod kątem lokalności danych. Zakres $[m, n]$ dzielony jest na bloki mieszczące się w pamięci cache L1/L2. Przetwarzanie blokowe znacząco przyspiesza operacje zapisu do tablicy wyników poprzez redukcję pudeł cache.

```
int calculate(int n, int m){
    //...alokacja pamieci i liczenie PrimeArray tak samo jak w kodzie k3

    int blockSize = 32768;
    int numberOfBlocks = (n - m) / blockSize;
    if ((n - m) % blockSize != 0) {
        numberOfBlocks++;
    }

    for (int i = 0; i < numberOfBlocks; i++) {
        int low = m + i * blockSize;
        int high = low + blockSize - 1;
        if (high > n) {
            high = n;
        }

        for (int j = 2; j * j <= high; j++) {
            if (primeArray[j] == true) {
                int firstMultiple = (low / j);
                if (firstMultiple <= 1) {
                    firstMultiple = j + j;
                } else if (low % j) {
                    firstMultiple = (firstMultiple * j) + j;
                }  else {
                    firstMultiple = (firstMultiple * j);
                }
                for (int k = firstMultiple; k <= high; k += j) {
                    result[k - m] = false;
                }
            }
        }
    }

        //...zliczanie prime_count i zwalnianie pamieci jak w kodzie k3
}
```

Listing 4: Kod programu k3a.cpp

K4 - Sito równoległe funkcyjne bez lokalności dostępu do danych.

Oznaczenie skrótowe: PAR-SIEVE-NL

Równoległe sito z podziałem funkcyjnym (`schedule(dynamic, 1)`). Wątki pobierają kolejne liczby pierwsze i wykreślają ich wielokrotności w całym zakresie wyników. Występuje zjawisko `false sharing` oraz bezpieczne wyścigi przy zapisie tej samej wartości logicznej pod ten sam indeks.

```
int calculate(int n, int m){
        //...alokacja pamieci i lizcenie PrimeArray jak wczesniej

        int limit = sqrt(n);
        #pragma omp parallel for schedule(dynamic, 1)
        for (int i = 2; i <= limit; i++){
                if (primeArray[i]) {
                        int firstMultiple = (m / i);
                        if (firstMultiple <= 1) {
                                firstMultiple = i + i;
                        } else if (m % i){
                                firstMultiple = (firstMultiple * i) + i;
                        } else {
                                firstMultiple = (firstMultiple * i);
                        }
                        for (int j = firstMultiple; j <= n; j+=i) {
                                result[j-m] = false;
                        }
                }
        }

        //zliczanie prime_count i zwalnianie pamieci jak wczesniej
}
```

Listing 5: Kod programu k4.cpp

K4a - Sito równoległe funkcyjne bez lokalności dostępu do danych z usunięciem redundancji zapisów.

Oznaczenie skrótowe: PAR-SIEVE-NL-A

Modyfikacja algorytmu K4 wprowadzająca warunkowy zapis do tablicy wyników (`if (result[j-m])`). Ma to na celu ograniczenie liczby operacji zapisu i związanych z nimi konfliktów w pamięci cache, co poprawia wydajność przy zachowaniu podziału funkcyjnego.

```
int calculate(int n, int m){
        //...alokacja pamieci i zliczanie PrimeArray jak wczesniej

        int limit = sqrt(n);
        #pragma omp parallel for schedule(dynamic, 1)
        for (int i = 2; i <= limit; i++){
                if (primeArray[i]) {
                        int firstMultiple = (m / i);
                        if (firstMultiple <= 1) {
                                firstMultiple = i + i;
                        } else if (m % i){
                                firstMultiple = (firstMultiple * i) + i;
                        } else {
                                firstMultiple = (firstMultiple * i);
                        }
                        for (int j = firstMultiple; j <= n; j+=i) {
                                if (result[j-m]) result[j-m] = false;
                        }
                }
        }

        //zliczanie prime_counter i zwalnianie pamieci jak w k4
}
```

Listing 6: Kod programu k4a.cpp

K5 - Sito równoległe domenowe z lokalnością dostępu do danych

Oznaczenie skrótowe: PAR-SIEVE-DOM-LL

Równoległe sito segmentowe z podziałem domenowym. Każdy wątek przetwarza niezależne bloki danych mieszczące się w cache, co eliminuje `false sharing` i wyścigi. Choć wydawałoby się, że `schedule(static)` minimalizuje narzut synchronizacji przy wyrównanym obciążeniu bloków, to jednak znacznie lepszy performormance zaobserwowaliśmy przy `schedule(guided)`.

```
int calculate(m, n){
        //...alokacja pamieci i liczenie PrimeArray jak wczesniej

        int blockSize = 32768;
        int numberOfBlocks = (n - m) / blockSize + ((n - m) % blockSize != 0);

        #pragma omp parallel for schedule(guided)
        for (int i = 0; i < numberOfBlocks; i++) {
                int low = m + i * blockSize;
                int high = low + blockSize - 1;
                if (high > n) high = n;

                for (int j = 2; j * j <= high; j++) {
                        if (primeArray[j]) {
                                int firstMultiple = (low / j) * j;
                                if (firstMultiple < low) firstMultiple += j;
                                if (firstMultiple == j) firstMultiple += j;

                                for (int k = firstMultiple; k <= high; k += j) {
                                        result[k - m] = false;
                                }
                        }
                }
        }

        //zliczanie prime_counter i zwalnianie pamieci jak wczesniej
}
```

Listing 7: Kod programu k5.cpp

3 Prezentacja wyników i omówienie przebiegu eksperymentu.

Zasady pracy z oprogramowaniem VTune.

Intel VTune Profiler to narzędzie do profilowania wydajności aplikacji na platformach Intel. W ramach przeprowadzonego eksperymentu wykorzystano tryb **Microarchitecture Exploration**, który umożliwia szczegółową analizę wykorzystania mikroarchitektury procesora poprzez zbieranie zdarzeń sprzętowych (hardware performance counters). Narzędzie mierzy m.in. liczbę wycofanych instrukcji (*Instructions Retired*), liczbę taktów procesora (*Clockticks*) oraz klasyfikuje przyczyny nieefektywności przetwarzania. Skorzystano również dla kodów równoległych z testu **Threading**, który pozwala na analizę efektywnego wykorzystania CPU oraz podziału czasu pracy między sekcję równoległą a sekwencyjną, oraz testu **Hotspots**, który daje informacje o czasie przetwarzania CPU i jego podziale między czas efektywny a czasy oczekiwania. W ramach analizy kodów k3 i k3a został też przeprowadzony test **Memory Access**, który pozwolił na analizę dostępów do pamięci.

Porównanie podstawowych parametrów wywołania dla kodów k1-k5.

Porównania zostały wykonane dla kodów przedstawionych w poprzedniej sekcji, z tymi samymi schedulingami i rozmiarami bloków na zakresie liczb od 1 do 100 milionów.

	k1	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
Elapsed Time [s]	23.750	2.394	0.660	0.130	0.381	0.296	0.060
Prędkość przetwarzania [mln l. pierwszych/s]	4.210	2.406	14.394	35.714	15.121	19.464	96.024
Instructions retired [mld]	405,744	405,599	0,515	0,777	2,179	1,501	1,702
Clockticks [miliardów tików]	105,112	166,746	2,914	0,566	19,808	14,777	1,995
Effective PCU	7.7%	68.9%	4.7%	7.1%	42.4%	51.5%	23.4%
Badania kodów równoległych	**k1**	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
Przyspieszenie względem k3a	-	0.05	-	-	0.34	0.43	2.17
Efektywność [Acc/Cores]	-	0.004	-	-	0.028	0.036	0.180

Tablica 2: Porównanie podstawowych parametrów wywołania dla kodów k1-k5.

Performance Cores	**k1**	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
Retiring	66.0%	83.5%	1.2%	0.0%	1.1%	4.5%	25.0%
Front End Bound	11.4%	13.8%	0.0%	3.1%	3.6%	20.0%	25.0%
Back End Bound	3.3%	1.7%	100.0%	0.0%	78.7%	58.0%	41.7%
Memory Bound	0.2%	0.2%	100.0%	0.0%	67.4%	42.6%	16.7%
Core Bound	3.1%	1.5%	0.0%	0.0%	11.4%	15.3%	25.0%
Efficient Cores	**k1**	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
Retiring	0.0%	42.3%	0.0%	0.0%	3.0%	0.7%	0.0%
Front End Bound	0.0%	5.0%	0.0%	0.0%	1.3%	3.8%	0.0%
Back End Bound	4.1%	11.5%	0.0%	0.0%	90.8%	34.8%	97.4%
Memory Bound	0.0%	0.2%	0.0%	0.0%	53.0%	34.8%	18.8%
Core Bound	4.1%	11.3%	0.0%	0.0%	37.8%	0.0%	78.6%

Tablica 3: Wyniki analizy przyczyn ograniczeń wydajności dla kodów k1-k5 z podziałem na Performance i Efficient Cores.

Porównanie działań kodów dla różnych zakresów liczb.

W ramach tego eksperymentu zmierzyliśmy Ellapsed Time dla kodów k1-k5 dla trzech różnych zakresów liczb: <2; max>, <max/2; max> oraz <2; max/2>, gdzie `max` to 10^8.

Zakres liczb	**k1**	**k2**	**k3**	**k3a**	**k4**	**k4a**	**k5**
<2; max>	23.750 s	2.394 s	0.660 s	0.130 s	0.381 s	0.296 s	0.060 s
<max/2; max>	16.671 s	3.852 s	0.303 s	0.069 s	0.279 s	0.122 s	0.038 s
<2; max/2>	7.116 s	2.450 s	0.282 s	0.065 s	0.225 s	0.117 s	0.050 s

Tablica 4: Porównanie prędkości działania dla różnych zakresów liczb w kodach k1-k5.

Porównanie zakresów ujawnia różne zachowania algorytmów w zależności od położenia zakresu. Dla **k1 i k2** (dzielenie próbne) czas silnie zależy od gęstości liczb pierwszych i wartości sprawdzanych liczb. Zakres $\langle \max/2; \max \rangle$ trwa dłużej niż $\langle 2; \max/2 \rangle$, ponieważ duże liczby wymagają sprawdzenia więcej dzielników (do $\sqrt{i}$). Dla **k3, k3a, k4, k4a, k5** (sito) czas nie zależy od wartości sprawdzanych liczb, lecz przede wszystkim od **rozmiaru zakresu**. Złożoność segmentowego sita Eratostenesa dla zakresu $\langle m, n \rangle$ wynosi $O(L \cdot \log\log n)$, gdzie $L = n - m$ to rozmiar zakresu, a n to górna granica. Ponieważ $\log\log n$ zmienia się bardzo wolno i jest niemal identyczne dla obu półzakresów, czas przetwarzania jest w przybliżeniu proporcjonalny do L — stąd oba półzakresy mają zbliżone czasy, mniejsze niż pełny zakres.

Badanie wpływu różnych szeregowań dla czasu przetwarzania kodów k2, k4, k4a i k5.

Schedule	**k2**	**k4**	**k4a**	**k5**
static	6.339 s	0.551 s	0.541 s	0.151 s
dynamic	2.475 s	0.296 s	0.381 s	0.080 s
guided	2.394 s	0.558 s	0.727 s	0.060 s

Tablica 5: Wpływy szeregowań na czas przetwarzania kodów równoległych.

Porównanie parametrów przetwarzania kodów k3 i k3a.

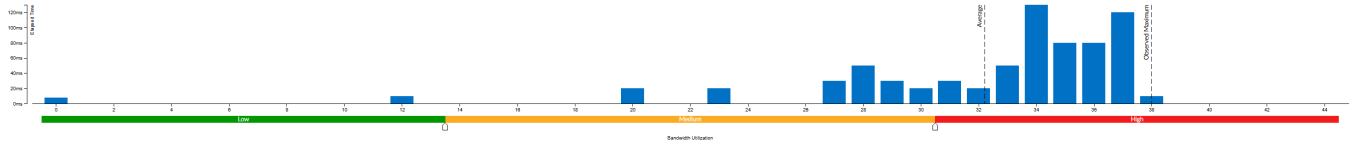

Rysunek 1: Wynik testu Memory Access BandwitdhHistogram dla kodu k3.

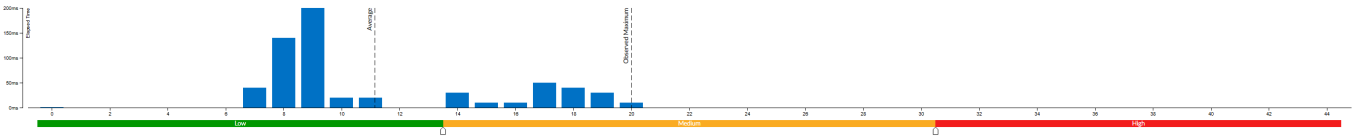

Rysunek 2: Wynik testu Memory Access BandwitdhHistogram dla kodu k3a.

	k3	**k3a**
PC L1 Bound	0.0%	0.0%
PC L2 Bound	1.1%	0.0%
PC L3 Bound	1.5%	0.0%
Store Bound	82.6%	0.0%
EC L1 Bound	0.0%	1.6%
EC L2 Bound	0.0%	0.0%
EC L3 Bound	0.0%	0.0%

Tablica 6: Porównanie czasów oczekiwania Memory Bound dla kodów k3 i k3a

Wyniki eksperymentu wyznaczania wielkości bloku dla kodów k3a i k5.

Aby wyznaczyć optymalną wielkość bloku dla kodów k3a i k5 napisaliśmy eksperyment, który wywoływał te kody dla standardowego zakres <2; max> z różnymi rozmiarami bloków od 16B do ilości liczb w zakresie z krokiem x2. Poniżej znajduje się część tabeli wynikowej, w której na środku znajduje się nasze poszukiwane optimum.

Blocksize	**k3a**	**k5**
4096	0.382 s	0.061 s
8192	0.229 s	0.040 s
16384	0.145 s	0.036 s
32768	0.107 s	0.030 s
65536	0.120 s	0.031 s
131072	0.121 s	0.039 s
262144	0.126 s	0.035 s
524288	0.128 s	0.040 s

Tablica 7: Wpływ rozmiaru bloku na czas przetwarzania kodów k3a i k5.

Optymalny rozmiar bloku wynosi **32768 elementów** (32 kB) dla obu kodów k3a i k5. Jest to wynik, którego możemy się spodziewać po sprawdzeniu parametrów procesora: choć posiada on ogółem 1 MB na pamięci L1, podzielona jest ona między 12 rdzeni, z czego 8 to rdzenie Performance z 48 kB cache L1, a pozostałe 4 to rdzenie Efficient z 32 kB cache L1. Z tych względów rozmiar bloku 32 kB będzie optymalny, będzie mieścił się w cache L1 obu typów rdzeni, jednocześnie będąc na tyle dużym aby zredukować niepotrzebny narzut związany z pobieraniem mniejszych ale większej liczby bloków z pamięci głównej do cache. Większy blok nie mieściłby się już zaś w L1, zmuszając do przenoszenia danych do wolniejszej pamięci L2, co ponownie zaczyna skutkować spadkiem wydajności.

Dodatkowy eksperyment: zwiększenia zakresu liczb do 1 miliarda.

W czasie przetwarzania kodów równoległych w standardowym zakresie <2;100 mln> zauważyliśmy, że czasy przetwarzania są bardzo krótkie, co utrudnia dokładną analizę wydajności. Dlatego zdecydowaliśmy się na dodatkowy eksperyment, w którym zwiększyliśmy zakres liczb do 1 miliarda. Poniżej przedstawiamy porównania wyników testu threading dla kodu równoległego k4.

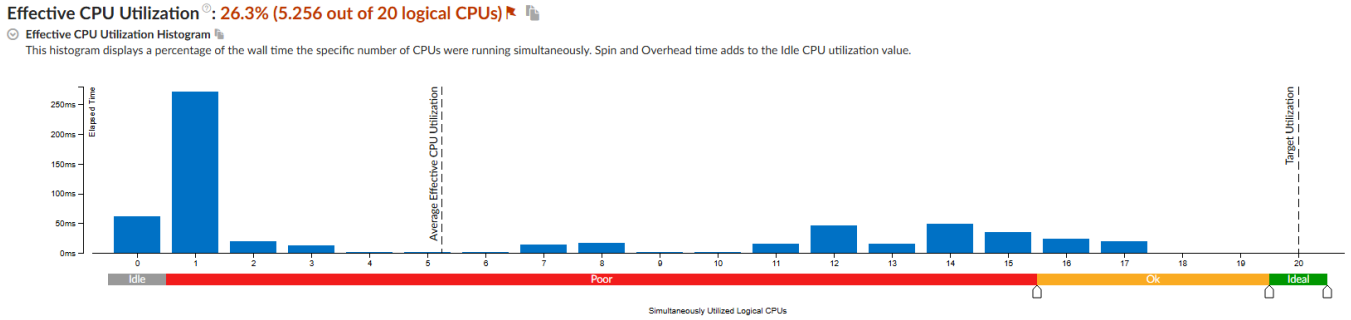

Rysunek 3: Wynik testu threading k4 dla zakresu <2; 100 mln>.

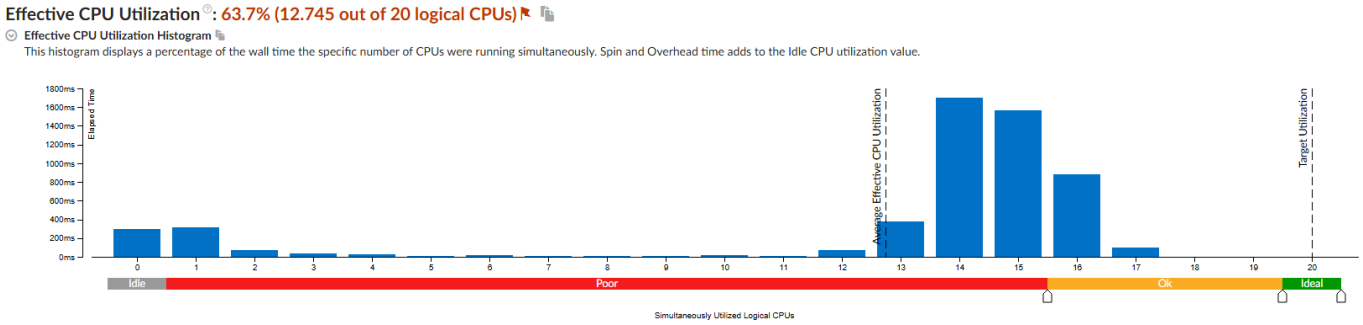

Rysunek 4: Wynik testu threading k4 dla zakresu <2; 1 mld>.

Pierwsze co rzuca się przy analizie wyżej przedstawionych wykresów to znaczny wzrost efektywności CPU z 26.3% na 63.7% po zwiększeniu zakresu. Czas spędzony na pracy 0 lub 1 wątku pozostaje w obu wypadkach taki sam: w sumie około 0.6 s. Cały dodatkowy czas wykonania to czas spędzony w sekcji równoległej, który wzrósł z 0.267 s na 4.871 s. Z wykresu widać że najwięcej czasu kod wykonuje jednocześnie 14 wątków, a nie 1 jak w przypadku rysunku 1. Podobne wyniki zaobserwowaliśmy dla reszty równoległych kodów. Widzimy więc, że niska wydajność kodów nie wynika z ich złej implementacji, a zbyt małego zakresu liczb w teście, który nie pozwalał na efektywne wykorzystanie potencjału równoległego procesora.

4 Wnioski.